

Laboratorium maszynowej analizy danych

Laboratorium 6

PROJEKT 1. UCZENIE MASZYNOWE.

Proszę o pobranie danych ze źródła:

<https://www.kaggle.com/datasets/blastchar/telco-customer-churn>

Churn klientów odnosi się do zjawiska, w którym klienci przerywają swoją relację lub subskrypcję z firmą lub dostawcą usług. Reprezentuje on wskaźnik, z jakim klienci przestają korzystać z produktów lub usług firmy w określonym okresie. Churn jest ważnym wskaźnikiem dla firm, ponieważ bezpośrednio wpływa na przychody, wzrost oraz retencję klientów.

W kontekście zbioru danych dotyczących churnu, etykieta churn wskazuje, czy klient odszedł, czy nie. Klient, który odszedł, to osoba, która zdecydowała się zakończyć subskrypcję lub korzystanie z usług firmy. Z kolei klient, który nie odszedł, to taki, który nadal jest zaangażowany i utrzymuje relację z firmą.

Zrozumienie churnu klientów jest kluczowe dla firm, aby zidentyfikować wzorce, czynniki i wskaźniki, które przyczyniają się do odpływu klientów. Analizując zachowania związane z churnem i powiązane z nimi cechy, firmy mogą opracować strategie mające na celu zatrzymanie obecnych klientów, poprawę ich satysfakcji oraz zmniejszenie odpływu. Techniki modelowania predykcyjnego mogą być również stosowane do przewidywania i proaktywnego przeciwdziałania potencjalnemu churnowi, co umożliwia firmom podejmowanie działań w celu zatrzymania klientów narażonych na odejście.

Zbiór danych zawiera informacje na temat:

- Klientów, którzy odeszli w ciągu ostatniego miesiąca – kolumna nosi nazwę "Churn".
- Usług, na które każdy klient się zapisał – telefon, wiele linii, internet, ochrona online, kopia zapasowa online, ochrona urządzeń, wsparcie techniczne oraz streaming TV i filmów.
- Informacji o koncie klienta – jak długo są klientami, rodzaj umowy, metoda płatności, e-faktura, miesięczne opłaty oraz łączne opłaty.
- Danych demograficznych klientów – płeć, przedział wiekowy oraz informacja o tym, czy mają partnerów i osoby zależne (dzieci, członków rodziny).

Wykorzystując model drzewa decyzyjnego, k-najbliższych sąsiadów oraz regresji logistycznej, należy przewidywać zachowania klientów.

Warto zastanowić się nad odpowiedzią na następujące pytania:

- Jaki procent klientów odchodzi, a ilu kontynuuje korzystanie z aktywnych usług?
- Czy istnieją wzorce wśród odchodzących klientów w zależności od płci?

- Czy są jakieś wzorce/preferencje wśród odchodzących klientów w zależności od rodzaju oferowanych usług?
- Jakie typy usług są najbardziej dochodowe?

Przygotowanie danych

1.1. Wczytanie danych, sprawdzenie typów danych i kompletności danych, podstawowe statystyki.

1.2. Utworzenie wykresu słupkowego:

1.2.1. ilości wystąpień kategorii dotyczącej atrybutu decyzyjnego,

1.2.2. atrybut decyzyjny według płci.

1.3. Wykres pudełkowy:

1.3.1. opłat całkowitych w zależności od klientów, którzy odeszli w ciągu ostatniego miesiąca.

1.3.2. 'churn' klientów w zależności długości czasu korzystania z usług.

1.4. Wykres pudełkowy opłat całkowitych w zależności od rodzaju umowy z uwzględnieniem, klientów, którzy odeszli w ciągu ostatniego miesiąca 'Churn'.

1.5. Utworzenie wykresu słupkowego wielkości korelacji z wyłączeniem cech ('customerID', 'tenure', 'MonthlyCharges', 'TotalCharges') z 'Churn' yes. Niektóre kolumny kategoryjne należy przekonwertować na zmienne fikcyjne.

1.6. Jakie są rodzaje zawieranych umów?

1.7. Rozkład różnych usług używanych przez klientów.

1.8. Utworzenie histogramu przedstawiającego rozkład długości czasu korzystania z usług (zmienna 'tenure').

1.9. Utworzenie histogramu przedstawiającego rozkład długości czasu korzystania z usług (zmienna 'tenure'), z różnicowaniem według klientów, którzy odeszli w ciągu ostatniego miesiąca oraz typu umowy.

1.10. Traktując każdą unikalną grupę 'tenure' jako kohortę (kohorta to grupa klientów, którzy mają wspólną cechę w określonym czasie. W kontekście analizy danych dotyczących churnu, kohorta może być definiowana na podstawie długości czasu korzystania z usług firmy), należy obliczyć współczynnik rezygnacji (procent osób, które zadeklarowały rezygnację) dla każdej kohorty. Na przykład w kohorcie z 1-miesięcznym stażem wskaźnik rezygnacji wynosi 61,99%. Kohorty powinny obejmować staż od 1 do 72 miesięcy, z ogólną tendencją, że im dłuższy czasu korzystania z usług, tym niższy współczynnik rezygnacji.

1.11. Wykres zależności współczynnika rezygnacji od 'tenure' w miesiącach.

1.12. Na podstawie wartości kolumny 'tenure' należy stworzyć nową kolumnę, dzieląc 'tenure' na 4 grupy: '0-12 miesięcy', '12-24 miesięcy', '24-48 miesięcy', 'Powyżej 48 miesięcy'.

1.13. Wykres pudełkowy długości czasu korzystania z usług ('tenure') podzielony na 4 grupy w zależności od 'Churn'.

Podział zbioru

- 2.1. Podział danych na macierz cech oraz etykiety. Należy stworzyć obiekt DataFrame z odpowiednimi zmiennymi fikcyjnymi. Należy pamiętać, że niektóre kolumny można pominąć.
- 2.2. Podział zbioru danych na treningowy i testowy, z ustawionym `random_state=42`, tak aby zbiór testowy zawierał co najmniej 1100 przykładów.

Wybór, optymalizacja modeli oraz ewaluacja

3. Model drzewa decyzyjnego

- 3.1. Zastosowanie klasyfikatora drzewa decyzyjnego przy ustawieniach domyślnych.
- 3.2. Wyświetlenie raportu z klasyfikacji oraz macierzy błędów i drzewo decyzyjne na podstawie predykcji na zbiorze testowym.
- 3.3. Informacja nt. wagi cech.

4. Model k-najbliższych sąsiadów

- 4.1. Zastosowanie klasyfikatora k-najbliższych sąsiadów przy ustawieniach domyślnych.
- 4.2. Wyświetlenie raportu z klasyfikacji oraz macierzy błędów na podstawie predykcji na zbiorze testowym.

5. Model regresji logistycznej

- 5.1. Zastosowanie klasyfikatora regresji logistycznej przy ustawieniach domyślnych.
- 5.2. Wyświetlenie raportu z klasyfikacji oraz macierzy błędów na podstawie predykcji na zbiorze testowym.

6. Porównanie klasyfikatorów

- 6.1. Który niezoptymalizowany klasyfikator działał najlepiej?
- 6.2. Zastosować metodę przeszukiwania siatki lub przeszukiwania losowego w celu doboru optymalnych parametrów i zbudowanie odpowiednio modelu drzewa decyzyjnego, k-najbliższych sąsiadów i regresji logistycznej. Należy wyświetlić raporty z klasyfikacji oraz macierze błędów na podstawie predykcji na zbiorze testowym dla każdego z zoptymalizowanych klasyfikatorów.
- 6.3. Który zoptymalizowany klasyfikator działał najlepiej? Który model zoptymalizowany wykazał największą poprawę klasyfikacji względem klasyfikatora niezoptymalizowanego?

UWAGI DO SPRAWOZDANIA

Wyniki i dyskusja

- Jaki procent klientów odchodzi, a ilu kontynuuje korzystanie z aktywnych usług?
- Czy istnieją wzorce wśród odchodzących klientów w zależności od płci?
- Czy są jakieś wzorce/preferencje wśród odchodzących klientów w zależności od rodzaju oferowanych usług?
- Jakie typy usług są najbardziej dochodowe?

Ewaluacja modeli za pomocą raportu z klasyfikacji oraz macierzy błędów dla modeli niezoptymalizowanych oraz zoptymalizowanych + Informacja nt. wagi cech dla drzewa decyzyjnego (model niezoptymalizowany oraz zoptymalizowany).

Podsumowanie

Porównanie klasyfikatorów

- Który niezoptymalizowany klasyfikator działał najlepiej?
- Który zoptymalizowany klasyfikator działał najlepiej? Który model zoptymalizowany wykazał największą poprawę klasyfikacji względem klasyfikatora niezoptymalizowanego?