

Laboratorium maszynowej analizy danych

Laboratorium 7

Wprowadzenie do wyjaśnialnej sztucznej inteligencji. Algorytm LIME.

Wprowadzenie

Algorytm LIME (ang. *Local Interpretable Model-agnostic Explanations*):

- ❑ *Local* – używa lokalnie ważonej regresji liniowej do wytłumaczenia konkretnej obserwacji,
- ❑ *Interpretable Explanations* – pozwala na zrozumienie co model robi, które cechy wybiera w celu stworzenia klasyfikatora,
- ❑ *Model-Agnostic* – traktuje model jako czarną skrzynkę (analizuje wejścia i wyjścia modelu).

Generowanie wyjaśnienia lokalnego:

1. Zbudowanie klasycznego modelu uczenia maszynowego.
2. Wyjaśnienie lokalne:
 - 2.1. Tworzenie instancji LIME.
 - 2.2. Wyjaśnienie dla danego obiektu:

Typy *Explainera*:

1. `lime_tabular` - dane ustrukturyzowane:

Klasa *LimeTabularExplainer*

2. `lime_text` - dane tekstowe:

Klasa *LimeTextExplainer*

3. `lime_image` - dane obrazowe:

Klasa *LimeImageExplainer*

- 2.3. Interpretacja wpływu poszczególnych cech na predykcję.

Wizualizacja wagi najważniejszych cech:

- `show_in_notebook()`
- `as_list()`
- `as_map()`
- `as_html()`
- `as_pyplot_figure()`

Zadania

Zadanie 1. Zastosowanie algorytmu LIME do problemu klasyfikacji binarnej – wyjaśnienie predykcji modelu wykorzystywanego do przewidywania prawdopodobieństwa zachorowania na cukrzycę na podstawie danych medycznych.

Opis danych jest dostępny na stronie:
<https://www.kaggle.com/datasets/akshaydattatraykhare/diabetes-dataset>

Zbiór danych dotyczy grupy pacjentek, u których na podstawie pomiarów laboratoryjnych oraz wywiadu środowiskowego można stwierdzić cukrzycę:

Pregnancies: liczba przeżytych ciąż,

Glucose: poziom glukozy we krwi (mg/dl),

BloodPressure: ciśnieni rozkurczowe krwi (mm Hg),

SkinThickness: grubość fałdu skórno mięśnia trójgłowego (mm),

Insulin: poziom insuliny we krwi (mIU/L),

BMI: indeks BMI,

DiabetesPedigreeFunction: współczynnik zachorowalności na cukrzycę w rodzinie,

Age: Wiek (lata),

Outcome: informacja, czy dana pacjentka jest chora na cukrzycę (Yes - 1) czy nie (No - 0).

Klasyfikacja za pomocą klasycznego modelu ML

1. Import odpowiednich bibliotek.
2. Przygotowanie danych.
3. Podział zbioru na macierz cech (X) oraz wektor wartości docelowych (y).
4. Podziału zbioru na zbiór treningowy i testowy. Zbiór testowy, będzie stanowił 30% całego zbioru danych. Stratyfikacja względem etykiet. Zarodek liczb losowych = 101.
5. Zbudowanie modelu regresji logistycznej.
6. Wytrenowanie modelu.
7. Wypróbowanie modelu na zbiorze testowym.
8. Ewaluacja modelu na podstawie raportu z klasyfikacji i macierzy błędów.

Wyjaśnienie klasyfikacji za pomocą algorytmu LIME

1. Import odpowiednich bibliotek.
2. Stworzenie nazw 2 klas decyzyjnych.
3. Stworzenie listy z nazwami kolumn.
4. Stworzenie wyjaśnienia z wykorzystaniem klasy *LimeTabularExplainer*. W tym celu należy stworzyć obiekt *explainer*, który będzie trenowany na zestawie uczącym.

5. Wyjaśnienie lokalnie wyników dla 4 różnych przypadków klasyfikacji (wyświetlenie etykiety rzeczywistej, etykiety przewidzianej oraz indeks obserwacji): TN, FP, FN i TP, uwzględniając prawdopodobieństwo i cechy mające największy wpływ na predykcję.

Zadanie 2.

Proszę o pobranie danych ze źródła:

<https://www.kaggle.com/code/shreayan98c/boston-house-price-prediction/input>

Zbiór danych zawiera informacje o wartościach nieruchomości w Bostonie. Celem problemu jest przewidywanie ceny domu na podstawie 13 cech opisujących nieruchomości. Model uczenia maszynowego prognozuje cenę domu, a następnie przy pomocy algorytmu LIME wyjaśniane są predykcje modelu. Zbiór danych zawiera 506 obserwacji oraz zmienną decyzyjną – cenę nieruchomości.

CRIM - współczynnik przestępczości w mieście,

ZN - odsetek "dużych działek" - powyżej 2500 m²,

INDUS - odsetek terenów industrialnych w mieście,

CHAS - jeśli teren znajduje się przy rzece Charles -1, w pozostałych przypadkach 0,

NOX - stężenie tlenków azotu,

RM - średnia ilość pomieszczeń w budynku,

AGE - odsetek "starych budynków" - powstałych przed 1940 r.,

DIS - ważona odległość od urzędów pracy w Bostonie,

RAD - wskaźnik dostępności do głównych dróg,

TAX - wartość podatku od nieruchomości liczona od 10 tys. dolarów,

PTRATIO - stosunek liczby uczniów na nauczycieli w mieście,

B - odsetek osób pochodzenia afroamerykańskiego,

LSTAT - odsetek mieszkańców zaliczany do ubogich (odsetek ubóstwa),

MEDV - mediana wartości domów z danego terenu (w tys. dolarów).

Regresja za pomocą klasycznego modelu ML

1. Import odpowiednich bibliotek.
2. Przygotowanie danych.
3. Podział zbioru na macierz cech (X) oraz wektor wartości docelowych (y).
4. Podziału zbioru na zbiór treningowy i testowy. Zbiór testowy, będzie stanowił 10% całego zbioru danych. Stratyfikacja ze względu na atrybut decyzyjny. Zarodek liczb losowych = 42.
5. Zbudowanie modelu regresji liniowej korzystając z algorytmu regresji opartego na ekstremalnych drzewa losowych (klasa *ExtraTreesRegressor*).
6. Wytrenowanie modelu.
7. Wypróbowanie modelu na zbiorze testowym.
8. Ewaluacja modelu.

Wyjaśnienie regresji za pomocą algorytmu LIME

1. Import odpowiednich bibliotek.
2. Stworzenie wyjaśnienia z wykorzystaniem klasy *LimeTabularExplainer*. W tym celu należy stworzyć obiekt *explainer*, który będzie trenowany na zestawie uczącym.
3. Wyjaśnienie lokalne - jakie parametry wpływają na predykcję w konkretnym przypadku?
 - o wyjaśnienie dla 4 przypadków (jaka jest rzeczywista cena domu, jaka jest przewidywana cena domu, jakie cechy wpływają na relatywnie wysoką/niską cenę domu).

Zadanie 3.

Proszę o pobranie danych SMSSpamCollection (zawierające wiadomości SMS oznaczone jako spam lub ham)

<https://archive.ics.uci.edu/ml/machine-learning-databases/00228/smsspamcollection.zip>

Klasyfikacja tekstu za pomocą klasycznego modelu ML

1. Import odpowiednich bibliotek.
2. Podział zbioru na macierz cech (X) oraz wektor wartości docelowych (y).
3. Podziału zbioru na zbiór treningowy i testowy. Zbiór testowy, będzie stanowił 25% całego zbioru danych. Stratyfikacja względem etykiet. Zarodek liczb losowych = 42
4. Przeprowadzenie transformacji danych tekstowych przy użyciu TF-IDF vectorizer.
5. Zbudowanie modelu lasów losowych.
6. Wytrenowanie modelu.
7. Wypróbowanie modelu na zbiorze testowym.
8. Ewaluacja modelu na podstawie raportu z klasyfikacji i macierzy błędów.

Wyjaśnienie klasyfikacji tekstu za pomocą algorytmu LIME

1. Import odpowiednich bibliotek.
2. Utworzenie wyjaśnienia przy pomocy klasy *LimeTextExplainer*, dopasowując *explainer* do danych treningowych.
3. Wyjaśnienie lokalnie wyników dla 4 różnych przypadków klasyfikacji wyświetlenie etykiety rzeczywistej, etykiety przewidzianej oraz indeks obserwacji: True Negative (TN), False Positive (FP), False Negative (FN), i True Positive (TP), uwzględniając prawdopodobieństwo i cechy mające największy wpływ na predykcję.

Literatura

1. A. Géron, *Uczenie maszynowe z użyciem Scikit-Learn, Keras, i TensorFlow*, Wydanie III, Helion, 2023.
2. S.J. Russell, P. Norvig, *Sztuczna inteligencja. Nowe spojrzenie*, Wydanie IV, Helion, 2023.
3. M. T. Ribeiro, S. Singh, and C. Guestrin, "Why should I trust you?" explaining the predictions of any classifier, Proceedings of the 22nd ACM SIGKDD international conference on knowledge discovery and data mining, 1135–1144, 2016.
4. W. J. Murdoch, C. Singh, K. Kumbier, B Yu, *Definitions, methods, and applications in interpretable machine learning*, PNAS, 116(44), 22073 (2019).
5. M. T. Ribeiro, S. Singh, and C. Guestrin, *Local Interpretable Model-Agnostic Explanations (LIME): An Introduction*.
6. C. Molnar, *Interpretable Machine Learning: A Guide For Making Black Box Models Explainable*, 2022.

UWAGI DO SPRAWOZDANIA

Sprawozdanie zawiera rozwiązanie zadania 1, zadania 2 oraz zadania 3.

Wyniki i dyskusja

Zadanie 1.

Ewaluacja klasycznego modelu ML na podstawie raportu z klasyfikacji i macierzy błędów.

Wyjaśnienie lokalnie wyników dla 4 różnych przypadków klasyfikacji (wyświetlenie etykiety rzeczywistej, etykiety przewidzianej oraz indeks obserwacji): TN, FP, FN i TP, uwzględniając prawdopodobieństwo i cechy mające największy wpływ na predykcję.

Zadanie 2.

Ewaluacja modelu regresyjnego.

Wyjaśnienie lokalne - jakie parametry wpływają na predykcję w konkretnym przypadku? Wyjaśnienie dla 4 przypadków (jaka jest rzeczywista cena domu, jaka jest przewidywana cena domu, jakie cechy wpływają na relatywnie wysoką/niską cenę domu).

Zadanie 3.

Ewaluacja klasycznego modelu klasyfikacji tekstu na podstawie raportu z klasyfikacji i macierzy błędów.

Wyjaśnienie lokalnie wyników dla 4 różnych przypadków klasyfikacji (wyświetlenie etykiety rzeczywistej, etykiety przewidzianej oraz indeks obserwacji): True Negative (TN), False Positive (FP), False Negative (FN), i True Positive (TP), uwzględniając prawdopodobieństwo i cechy mające największy wpływ na predykcję.