

Julia Duch, Magda Jaźwińska		2024 / 2025		Programowanie systemów inteligentnych			
AUTOR		ROK AKAD.		SPEC.		2	GRUPA
WYKORZYSTANIE KLASYCZNYCH MODELI UCZENIA MASZYNOWEGO DO ROZWIĄZYWANIA PROBLEMÓW ML.						1	
				TEMAT		NR SPRAWOZDANIA	
12.11.2024	Zastosowania sztucznej inteligencji				dr. inż. Anna Czaderna-Lekka		
DATA WYKONANIA	PRZEDMIOT				PROWADZĄCY		

Spis treści

1. CEL	3
2. MATERIAŁY	3
2.1. PRZYGOTOWANIE DANYCH	4
3. METODY	5
4. WYNIKI I DYSKUSJA	7
4.1. Regresja Liniowa	7
4.2. Regresja Logistyczna	9
4.3. A K-Nearest Neighbors (KNN)	13
4.4. Maszyna Wektorów Nośnych (SVM)	16
4.5. Wykresy	21
4. PODSUMOWANIE	25
5. BIBLIOGRAFIA	26

1. CEL

Celem projektu było stworzenie i zastosowanie klasycznych modeli uczenia maszynowego w celu przewidywania, czy uczeń osiągnie wynik egzaminu powyżej 70%, na podstawie różnych czynników związanych z jego nauką, życiem rodzinnym i aktywnościami pozaszkolnymi, a następnie wykonanie optymalizacji modeli i porównanie uzyskanych wyników. Dodatkowo uzyskane wyniki porównano również z wynikami uzyskanymi przez modele nieoptymalizowane na danych zestandaryzowanych oraz znormalizowanych. Porównanie wyników umożliwiło ocenę efektywności modeli w wersji podstawowej oraz zoptymalizowanej.

2. MATERIAŁY

W niniejszej analizie wykorzystano zbiór danych StudentPerformanceFactors. Baza danych zawiera szczegółowe informacje o czynnikach wpływających na wyniki uczniów na egzaminach. Zawiera 6607 rekordów, a każda obserwacja składa się z 20 atrybutów opisujących różne aspekty życia ucznia, które mogą mieć wpływ na jego osiągnięcia akademickie. Baza zawiera następujące kolumny:

1. Hours_Studied – liczba godzin nauki tygodniowo.
2. Attendance – procent frekwencji na zajęciach.
3. Parental_Involvement – poziom zaangażowania rodziców w edukację ucznia (niski, średni, wysoki).
4. Access_to_Resources – dostępność zasobów edukacyjnych (niska, średnia, wysoka).
5. Extracurricular_Activities – uczestnictwo w zajęciach pozalekcyjnych (tak, nie).
6. Sleep_Hours – średnia liczba godzin snu na dobę.
7. Previous_Scores – wyniki z wcześniejszych egzaminów.
8. Motivation_Level – poziom motywacji ucznia (niski, średni, wysoki).
9. Internet_Access – dostęp do internetu (tak, nie).
10. Tutoring_Sessions – liczba sesji korepetycji w miesiącu.
11. Family_Income – poziom dochodów rodziny (niski, średni, wysoki).
12. Teacher_Quality – jakość nauczycieli (niska, średnia, wysoka).
13. School_Type – typ szkoły (publiczna, prywatna).
14. Peer_Influence – wpływ rówieśników na wyniki w nauce (pozytywny, neutralny, negatywny).
15. Physical_Activity – średnia liczba godzin aktywności fizycznej tygodniowo.
16. Learning_Disabilities – obecność trudności w uczeniu się (tak, nie).
17. Parental_Education_Level – najwyższy poziom wykształcenia rodziców (szkoła średnia, studia licencjackie, studia podyplomowe).
18. Distance_from_Home – odległość od domu do szkoły (blisko, umiarkowanie, daleko).
19. Gender – płeć ucznia (mężczyzna, kobieta).
20. Exam_Score – końcowy wynik egzaminu.

2.1. PRZYGOTOWANIE DANYCH

Dane zostały przetworzone, aby umożliwić skuteczne trenowanie modeli oraz wyeliminować problemy związane z brakującymi wartościami i zmiennymi kategorycznymi. Przekształcenia obejmowały:

1. Usunięcie zbędnych kolumn: Kolumny `Physical_Activity`, `Peer_Influence`, `Parental_Education_Level`, oraz `Family_Income` zostały usunięte, ponieważ nie były kluczowe dla analizy lub posiadały wartości, które mogłyby być trudne do dokładnego zakodowania.
2. Mapowanie wartości kategorycznych na numeryczne: Wybrane kolumny, które zawierały wartości kategoryczne o niskiej liczbie unikalnych wartości, zostały przekształcone przy użyciu mapowania:
 - `Gender`: przekształcone na 0 (Male) i 1 (Female).
 - `Distance_from_Home`: przekształcone na 0 (Near), 1 (Moderate) i 2 (Far).
 - `Access_to_Resources`, `Parental_Involvement`, `Motivation_Level`, `Teacher_Quality`: przekształcone na wartości 0 (Low), 1 (Medium) i 2 (High), co pozwoliło na przedstawienie ich jako liczb porządkowych.
3. Wypełnianie brakujących wartości:
 - Brakujące wartości w kolumnach `Distance_from_Home` oraz `Teacher_Quality` zostały zastąpione medianą tych kolumn.
4. Kodowanie zmiennych kategorycznych przy użyciu Dummy Encoding:
 - Kolumny o wyższej liczbie kategorii, takie jak `Learning_Disabilities`, `Internet_Access`, `School_Type`, oraz `Extracurricular_Activities`, zostały zakodowane jako zmienne binarne (0 lub 1) przy użyciu metody *get_dummies*, która tworzy nowe kolumny reprezentujące każdą z kategorii.
5. Przekształcenie wyniku egzaminu na zmienną binarną:
 - Kolumna `Exam_Score` została przekształcona na wartość binarną 1 dla wyników większych lub równych 70% oraz 0 dla wyników poniżej 70%. To przekształcenie pozwoliło na trenowanie modeli klasyfikacyjnych w celu przewidywania, czy uczeń osiągnął minimalny próg punktowy.

Te przekształcenia były kluczowe, aby zmienne kategoryczne mogły być wykorzystane w klasycznych modelach uczenia maszynowego, które wymagają reprezentacji liczbowej.

3. METODY

W ramach przeprowadzonego projektu zastosowano cztery klasyczne modele uczenia maszynowego, które zostały poddane treningowi zarówno w wersji podstawowej, jak i zoptymalizowanej. Modele, które zostały użyte, to: Regresja Liniowa (Linear Regression), Regresja Logistyczna (Logistic Regression), K-Nearest Neighbors (KNN) oraz Maszyna Wektorów Nośnych (SVM). Celem zastosowania modeli w tej analizie było przewidywanie, czy student uzyska wynik egzaminu powyżej 70 punktów. Do tego celu wykorzystano klasyfikację, gdzie wynik egzaminu został zakodowany jako zmienna binarna, przyjmująca wartość 1, jeśli wynik był wyższy niż 70 punktów, i wartość 0, jeśli wynik był niższy lub równy 70 punktów.

1. Regresja Liniowa (Linear Regression)

W wersji podstawowej regresja liniowa została zastosowana bez jakiegokolwiek regularyzacji. Model został wytrenowany na oryginalnych danych (po przekształceniach), a wyniki porównano z wynikami uzyskanymi po optymalizacji. W ramach optymalizacji modeli regresyjnych zastosowano trzy różne techniki regularyzacji: Ridge, Lasso oraz ElasticNet. Każdy z tych modeli został zoptymalizowany przy użyciu GridSearchCV, które umożliwia wyszukiwanie najlepszych hiperparametrów na podstawie określonej siatki wartości. Optymalizacja modelu Ridge polegała na znalezieniu najlepszego parametru α , który kontroluje stopień regularyzacji. Wartości α zostały dobrane z zakresu: [0.1, 1, 10, 100, 1000]. Optymalizacja modelu Lasso również polegała na doborze najlepszego parametru α . Dla tego modelu GridSearchCV przeszukiwał przestrzeń wartości α w zakresie: [0.01, 0.1, 1, 10, 100], wybierając wartość, która najlepiej minimalizowała błąd średniokwadratowy na danych treningowych. Optymalizacja modelu ElasticNet polegała na znalezieniu dwóch hiperparametrów: α , który kontroluje siłę regularyzacji, oraz $l1_ratio$, który określa, jaką wagę przypisać regularyzacji L1 (Lasso) w porównaniu do L2 (Ridge). Zostały przetestowane różne wartości α w zakresie: [0.01, 0.1, 1, 10, 100] oraz różne wartości $l1_ratio$ w zakresie: [0.1, 0.5, 0.7, 1]. Dla modelu Ridge najlepsze wyniki osiągnięto przy wartości $\alpha=10$. Dla modelu Lasso najlepsze wyniki osiągnięto przy wartości $\alpha = 0.01$. W przypadku modelu ElasticNet najlepsza kombinacja α oraz $l1_ratio$ wyniosła [0.01, 0.1].

2. Regresja logistyczna (Logistic Regression)

Początkowo model regresji logistycznej zastosowano bez optymalizacji. Optymalizacja tego modelu polegała na zastosowaniu GridSearchCV aby znaleźć najlepsze hiperparametry. Po zastosowaniu GridSearchCV model przeszukał przestrzeń parametrów, używając metody cross-validation ($cv=5$), czyli podziału danych na 5 części, z których każda była wykorzystywana jako zestaw testowy w jednej iteracji. Po zakończeniu procesu optymalizacji, najlepsze wartości hiperparametrów zostały wybrane, co pozwoliło na uzyskanie optymalnego modelu regresji logistycznej. Najlepsze wybrane hiperparametry modelu: C (parametr regularyzacji) = 100, $penalty$ (typ regularyzacji) = l1, $solver$ (algorytm optymalizacji) = liblinear.

3. A K-Nearest Neighbors

KNN jest modelem klasyfikacyjnym, który klasyfikuje dane na podstawie najbliższych sąsiadów. W wersji podstawowej model został wytrenowany z domyślną liczbą sąsiadów (5). Optymalizacja tego modelu polegała na zastosowaniu GridSearchCV w celu znalezienia optymalnej liczby sąsiadów (n_neighbors), metryki odległości (metrics) oraz wagi sąsiadów (weights). W wyniku optymalizacji modelu uzyskano najlepszą kombinację hiperparametrów: n_neighbors = 11, metric = manhattan, weights = uniform.

4. Maszyna Wektorów Nośnych (SVM)

Podobnie jak w przypadku pozostałych modeli, początkowo model SVM został wykorzystany bez optymalizacji. Optymalizacja modelu została przeprowadzona przy użyciu GridSearchCV, mając na celu znalezienie najlepszych wartości hiperparametrów, które poprawią jakość klasyfikacji. W tym przypadku, zoptymalizowane zostały cztery główne hiperparametry:

- C (parametr regularyzacji) o wartościach: 0.1, 1 i 10.
- kernel (funkcja jądra) - do optymalizacji wybrano dwa rodzaje jąder: linear (liniowe) oraz rbf (funkcja jądra Radial Basis Function).
- gamma (parametr kontrolujący rozkład funkcji jądra). Zoptymalizowano dwa ustawienia gamma: scale oraz auto.
- shrinking - ustawiony na opcję True.

Została uzyskana następująca najlepsza kombinacja:

```
{'C': 10, 'gamma': 'scale', 'kernel': 'linear', 'shrinking': True}
```

5. Standaryzacja i normalizacja danych

Po przeprowadzeniu optymalizacji modeli i porównaniu wyników modeli bez oraz z optymalizacją została wykonana jeszcze jedna analiza. Te same modele (bez optymalizacji) zostały użyte na danych zestandaryzowanych oraz znormalizowanych. Następnie porównano wyniki uzyskane na danych oryginalnych, zestandaryzowanych oraz znormalizowanych.

4. WYNIKI I DYSKUSJA

Każdy z wybranych modeli został wykorzystany najpierw bez optymalizacji a następnie z optymalizacją. Dodatkowo modele bez optymalizacji zostały wykorzystane ponownie na danych zestandaryzowanych oraz znormalizowanych. Uzyskano następujące wyniki:

4.1. Regresja Liniowa

Wyniki regresji liniowej bez zastosowanej regularyzacji:

```
Mean Absolute Error: 0.26020096884813143
Mean Squared Error: 0.09549293140351718
Root Mean Squared Error: 0.30901930587508153
R2 Score: 0.4852982568454889
```

R² (współczynnik determinacji) = 0.485: Wartość ta wskazuje, że model wyjaśnia około 48.5% wariacji wyników egzaminu. To średni wynik, sugerujący, że model uchwycił część zależności między cechami wejściowymi a wynikiem egzaminu, ale jest jeszcze sporo zmienności, której model nie wyjaśnia.

MAE (średni błąd bezwzględny) = 0.2602: MAE na poziomie 0.2602 oznacza, że średni błąd prognozy wynosi około 0.26 w skali binarnej, co można interpretować jako 26.02% średniego odchylenia prognoz od rzeczywistych wyników. Ponieważ wyniki egzaminu mają wartości 0 lub 1, wartość MAE sugeruje względnie umiarkowany poziom błędów.

RMSE (pierwiastek z średniego błędu kwadratowego) = 0.3090: RMSE, wynoszące 0.3090, wskazuje na przeciętną różnicę między przewidywanymi a rzeczywistymi wynikami egzaminu.

MSE (średni błąd kwadratowy) = 0.095: MSE na poziomie 0.095 oznacza średnią wartość błędu kwadratowego między przewidywaniami a rzeczywistymi wynikami.

Wyniki regresji liniowej z optymalizacją

Ridge:

```
Najlepsze parametry dla Ridge Regression: {'alpha': 10}
Mean Absolute Error (optimized): 0.26022625022828244
Mean Squared Error (optimized): 0.09550699478647341
Root Mean Squared Error (optimized): 0.30904205989876754
R2 Score (optimized): 0.4852224559708499
```

Lasso:

```
Lasso Regression - najlepsze parametry: {'alpha': 0.01}
Mean Absolute Error (Lasso): 0.2629417117550651
Mean Squared Error (Lasso): 0.09846911772770106
Root Mean Squared Error (Lasso): 0.3137978931218326
R2 Score (Lasso): 0.4692567732875379
```

ElasticNet:

```
ElasticNet - najlepsze parametry: {'alpha': 0.01, 'l1_ratio': 0.1}
Mean Absolute Error (ElasticNet): 0.2604392165785467
Mean Squared Error (ElasticNet): 0.09568973285143458
Root Mean Squared Error (ElasticNet): 0.3093375710311222
R2 Score (ElasticNet): 0.4842375076695066
```

Po optymalizacji trzech modeli regresyjnych (Ridge, Lasso i ElasticNet) wyniki są do siebie bardzo zbliżone, co sugeruje, że wszystkie modele osiągnęły porównywalną jakość przewidywań dla tej samej zmiennej.

1. **Ridge Regression:** MAE wynosi 0.2602, MSE wynosi 0.095, RMSE to 0.309, a R^2 osiąga 0.485.
2. **Lasso Regression:** MAE wynosi 0.2629, MSE to 0.0984, RMSE to 0.313, a R^2 wynosi 0.469.
3. **ElasticNet Regression:** MAE wynosi 0.2604, MSE to 0.095, RMSE to 0.3093, a R^2 to 0.484.

Spośród tych trzech modeli **najlepsze wyniki osiągnął model Ridge**, który uzyskał najniższe wartości MSE i RMSE oraz najwyższy współczynnik R^2 . Porównując wyniki Ridge Regression po optymalizacji z jej wersją podstawową, optymalizacja nie przyniosła poprawy.

Wyniki regresji liniowej dla danych zestandaryzowanych i znormalizowanych

```
Standardized Data Results:
MAE: 0.26
MSE: 0.10
RMSE: 0.31
R2 Score: 0.49

Normalized Data Results:
MAE: 0.26
MSE: 0.10
RMSE: 0.31
R2 Score: 0.49
```

Wnioski z wyników uzyskanych na danych zestandaryzowanych i znormalizowanych wskazują, że zarówno standaryzacja, jak i normalizacja przyniosły bardzo zbliżone rezultaty w porównaniu do modelu na oryginalnych danych, co można zauważyć po niemal identycznych wartościach wszystkich miar:

- **MAE (średni błąd bezwzględny):** Wynik MAE wynoszący 0.26 jest taki sam w przypadku danych standaryzowanych, znormalizowanych oraz oryginalnych, co wskazuje, że zmiana skali danych nie wpłynęła znacząco na średnią wartość błędów prognoz.
- **MSE (średni błąd kwadratowy) oraz RMSE (pierwiastek z MSE):** Zarówno MSE, jak i RMSE utrzymują się na poziomie odpowiednio 0.10 i 0.31 dla wszystkich trzech zestawów danych. Podobieństwo tych wyników potwierdza, że transformacje danych nie miały wpływu na rozkład większych błędów w modelu.
- **R² (współczynnik determinacji):** Wartość R² wynosi około 0.49 na danych standaryzowanych i znormalizowanych, co jest niewielką poprawą w stosunku do modelu na oryginalnych danych (0.485). Choć różnica jest minimalna, może sugerować, że przeskalowanie danych odrobinę zwiększyło zdolność modelu do uchwycenia zależności między cechami wejściowymi a wynikami.

Podsumowując, standaryzacja i normalizacja nie przyniosły znaczącej poprawy wyników modelu.

4.2. Regresja Logistyczna

Wyniki regresji logistycznej bez optymalizacji:

```
Confusion Matrix:
[[1455  40]
 [ 76 412]]

Classification Report:
              precision    recall  f1-score   support

     0       0.95      0.97      0.96      1495
     1       0.91      0.84      0.88       488

 accuracy          0.94      1983
 macro avg       0.93      0.91      0.92      1983
 weighted avg    0.94      0.94      0.94      1983

Accuracy: 0.9415027735753908
```

Analiza wyników regresji logistycznej pokazuje, że model osiągnął wysoką skuteczność w przewidywaniu, czy student uzyska wynik egzaminu powyżej 70%.

Analiza Confusion Matrix:

- **True Negatives (1455):** Model poprawnie przewidział 1455 przypadków, gdzie wynik był poniżej 70%.
- **False Positives (40):** W 40 przypadkach model przewidział wynik powyżej 70%, choć był poniżej tego progu.
- **False Negatives (76):** Model nieprawidłowo zaklasyfikował 76 przypadków, gdzie wynik był powyżej 70%, jako wynik poniżej 70%.
- **True Positives (412):** Model poprawnie przewidział 412 przypadków z wynikiem powyżej 70%.

Raport klasyfikacji:

- **Klasa 0 (wynik poniżej 70%):**
 - **Precyzja:** 0.95 — 95% przypadków, w których model przewidywał wynik poniżej 70%, były poprawne.
 - **Recall:** 0.97 — 97% rzeczywistych przypadków z wynikiem poniżej 70% zostało poprawnie zidentyfikowanych.
 - **F1-score:** 0.96 — Wysoki F1-score wskazuje na dobrą równowagę między precyzją a recall.
- **Klasa 1 (wynik powyżej 70%):**
 - **Precyzja:** 0.91 — 91% przewidywań powyżej 70% było poprawnych.
 - **Recall:** 0.84 — 84% rzeczywistych przypadków powyżej 70% zostało poprawnie zidentyfikowanych przez model.
 - **F1-score:** 0.88 — F1-score na poziomie 0.88 świadczy o wysokiej jakości przewidywań dla tej klasy, choć nieco niższy niż dla klasy 0.

Dokładność (Accuracy): 0.94 — Model poprawnie sklasyfikował 94% wszystkich przypadków, co wskazuje na wysoką ogólną skuteczność.

Macro avg i Weighted avg: Obie średnie pokazują wysokie wskaźniki, odpowiednio na poziomie 0.93 i 0.94, co oznacza, że model dobrze radzi sobie z przewidywaniem obu klas, nawet przy różnicy w liczebności.

Wyniki regresji logistycznej z zastosowaną optymalizacją:

```
Confusion Matrix (optimized):
[[1454  41]
 [ 77 411]]

Classification Report (optimized):
```

	precision	recall	f1-score	support
0	0.95	0.97	0.96	1495
1	0.91	0.84	0.87	488
accuracy			0.94	1983
macro avg	0.93	0.91	0.92	1983
weighted avg	0.94	0.94	0.94	1983

```
Accuracy (optimized): 0.940494200706001
```

Wyniki po optymalizacji dla regresji logistycznej są bardzo zbliżone do wyników uzyskanych przed optymalizacją, co oznacza, że dostrojenie parametrów modelu miało znikomy wpływ na jego wydajność.

Analiza Confusion Matrix po optymalizacji:

- **True Negatives:** Zmiana z 1455 na 1454 — o 1 przypadek mniej.
- **False Positives:** Zmiana z 40 na 41 — o 1 przypadek więcej.
- **False Negatives:** Zmiana z 76 na 77 — o 1 przypadek więcej.
- **True Positives:** Zmiana z 412 na 411 — o 1 przypadek mniej.

Porównanie raportu klasyfikacji:

- **Klasa 0:** F1-score pozostał na poziomie 0.96, a recall i precision pozostały praktycznie takie same.
- **Klasa 1:** F1-score spadł minimalnie z 0.88 do 0.87, co oznacza, że niewielkie różnice w rozkładzie błędów mają wpływ na jakość przewidywań dla klasy 1.
- **Dokładność (Accuracy):** Praktycznie bez zmian — wynik zmienił się minimalnie z 0.9415 do 0.9405.

Optymalizacja parametrów modelu nie przyniosła znaczącej poprawy wyników. Model nadal osiąga bardzo wysoką skuteczność, ale uzyskane drobne różnice sugerują, że model osiągnął już swoje optymalne wartości przed wprowadzeniem dostrojenia.

Wyniki regresji logistycznej dla danych zestandaryzowanych i znormalizowanych:

```
Accuracy on Standardized Data: 0.94
Accuracy on Normalized Data: 0.94

Classification Report (Standardized):
      precision    recall  f1-score   support

     0       0.95      0.97      0.96      1495
     1       0.91      0.84      0.88       488

 accuracy          0.94          1983
  macro avg       0.93      0.91      0.92      1983
weighted avg       0.94      0.94      0.94      1983

Classification Report (Normalized):
      precision    recall  f1-score   support

     0       0.94      0.98      0.96      1495
     1       0.93      0.82      0.87       488

 accuracy          0.94          1983
  macro avg       0.93      0.90      0.91      1983
weighted avg       0.94      0.94      0.94      1983
```

Analiza wyników dla danych zestandaryzowanych i znormalizowanych wskazuje, że oba podejścia przyniosły bardzo podobne rezultaty, z minimalnymi różnicami w wynikach.

Porównanie wyników dokładności:

- **Dokładność (Accuracy)** dla obu podejść wyniosła 0.94, co oznacza, że oba przekształcenia danych nie miały wpływu na ogólną trafność modelu.

Classification Report dla danych zestandaryzowanych:

- **Klasa 0:** Precision wynosi 0.95, recall 0.97, a F1-score 0.96, co wskazuje na bardzo dobrą skuteczność modelu dla tej klasy.
- **Klasa 1:** Wyniki dla klasy 1 osiągnęły precision 0.91, recall 0.84 i F1-score 0.88, co sugeruje, że model jest skuteczny, choć nieco mniej niż w przypadku klasy 0.

Classification Report dla danych znormalizowanych:

- **Klasa 0:** Wartość precision to 0.94, recall 0.98, a F1-score 0.96 — wynik jest porównywalny do wersji zestandaryzowanej, choć model nieznacznie lepiej wyłapuje klasę 0 (wyższy recall).

- **Klasa 1:** Wyniki dla klasy 1 (precision 0.93, recall 0.82, F1-score 0.87) są zbliżone do wyników uzyskanych dla danych zestandaryzowanych, choć recall jest niższy.

Porównując z wynikami regresji logistycznej na oryginalnych danych można stwierdzić że standaryzacja i normalizacja danych nie wpłynęła korzystnie na wyniki modelu. Accuracy zostało na tym samym poziomie 94%.

4.3. A K-Nearest Neighbors (KNN)

Wyniki KNN bez optymalizacji:

```
Confusion Matrix:
[[1392  103]
 [ 149  339]]

Classification Report:
              precision    recall  f1-score   support

     0       0.90      0.93      0.92      1495
     1       0.77      0.69      0.73       488

 accuracy      0.87      0.87      0.87      1983
 macro avg     0.84      0.81      0.82      1983
weighted avg     0.87      0.87      0.87      1983

Accuracy: 0.87
```

Analiza wyników regresji logistycznej pokazuje, że model osiągnął wysoką skuteczność w przewidywaniu, czy student uzyska wynik egzaminu powyżej 70%.

Analiza Confusion Matrix:

- **True Negatives (1392):** Model poprawnie przewidział 1392 przypadków, gdzie wynik był poniżej 70%.
- **False Positives (103):** W 103 przypadkach model przewidział wynik powyżej 70%, choć był poniżej tego progu.
- **False Negatives (149):** Model nieprawidłowo zaklasyfikował 149 przypadków, gdzie wynik był powyżej 70%, jako wynik poniżej 70%.
- **True Positives (339):** Model poprawnie przewidział 339 przypadków z wynikiem powyżej 70%.

Raport klasyfikacji:

- **Klasa 0 (wynik poniżej 70%):**
 - **Precyzja:** 0.9 — 90% przypadków, w których model przewidywał wynik poniżej 70%, były poprawne.
 - **Recall:** 0.93 — 93% rzeczywistych przypadków z wynikiem poniżej 70% zostało poprawnie zidentyfikowanych.
 - **F1-score:** 0.92 — Wysoki F1-score wskazuje na dobrą równowagę między precyzją a recall.

- **Klasa 1 (wynik powyżej 70%):**
 - **Precyzja:** 0.77 — 77% przewidywań powyżej 70% było poprawnych.
 - **Recall:** 0.69 — 69% rzeczywistych przypadków powyżej 70% zostało poprawnie zidentyfikowanych przez model.
 - **F1-score:** 0.73 — 73% wyniku F-score dla klasy 1 sugeruje, że model ma trudności z dokładnym przewidywaniem tej klasy i radzi sobie gorzej niż dla klasy 0.

Dokładność (Accuracy): 0.87 — Model poprawnie klasyfikuje 87% wszystkich przypadków. Jest to dobry wynik, ale można zauważyć pewną nierównowagę w rozpoznawaniu obu klas.

Wyniki KNN z zastosowaną optymalizacją:

```
Confusion Matrix (optimized):
[[1409   86]
 [ 146  342]]

Classification Report (optimized):
              precision    recall  f1-score   support

     0           0.91       0.94       0.92       1495
     1           0.80       0.70       0.75        488

 accuracy              0.88       1983
 macro avg           0.85       0.82       0.84       1983
weighted avg           0.88       0.88       0.88       1983

Accuracy (optimized): 0.88
```

Na podstawie wyników po optymalizacji dla algorytmu KNN możemy zauważyć pewną poprawę w klasyfikacji, zwłaszcza w obszarze precyzji dla obu klas.

Analiza Confusion Matrix po optymalizacji:

- **True Negatives:** Zmiana z 1392 na 1409 — o 17 przypadków więcej.
- **False Positives:** Zmiana z 103 na 86 — o 17 przypadków mniej.
- **False Negatives:** Zmiana z 149 na 146 — o 3 przypadki mniej.
- **True Positives:** Zmiana z 339 na 342 — o 3 przypadki więcej.

Porównanie raportu klasyfikacji:

- **Klasa 0:** F1-score pozostał na poziomie 0.92, a recall i precision minimalnie wzrosły, co pokazuje, że model po optymalizacji radzi sobie nieznacznie lepiej.
- **Klasa 1:** Precyzja dla klasy 1 również wzrosła (z 0.77 do 0.80), co wskazuje na lepsze wykrywanie rzeczywistych przypadków klasy 1. Czułość dla klasy 1 wzrosła nieznacznie, ale nadal pozostaje niższa niż dla klasy 0, co sugeruje, że pewna część przypadków klasy 1 jest nadal błędnie klasyfikowana jako klasa 0. Wynik f1 dla klasy 1 wzrósł po optymalizacji z 73% na 75%.

- **Dokładność (Accuracy):** Dokładność modelu wynosi 0.88, co oznacza, że model poprawnie klasyfikuje 88% wszystkich przypadków. Jest to wyraźna poprawa w stosunku do wyniku sprzed optymalizacji (0.87).

Po optymalizacji model KNN osiągnął lepszą dokładność i precyzję, zwłaszcza dla klasy 1. Precyzja i f1-score dla obu klas wzrosły, co oznacza, że model lepiej odwzorowuje rzeczywisty podział na klasy. Mimo że nadal występują trudności z pełnym rozróżnieniem klasy 1 (czułość dla tej klasy jest niższa), model znacznie poprawił swoje działanie w porównaniu do wersji bez optymalizacji.

Wyniki KNN dla danych zestandaryzowanych i znormalizowanych:

Accuracy on Standardized Data: 0.86				
Accuracy on Normalized Data: 0.84				
Classification Report (Standardized):				
	precision	recall	f1-score	support
0	0.87	0.96	0.91	1495
1	0.82	0.55	0.66	488
accuracy			0.86	1983
macro avg	0.84	0.76	0.79	1983
weighted avg	0.86	0.86	0.85	1983
Classification Report (Normalized):				
	precision	recall	f1-score	support
0	0.85	0.96	0.90	1495
1	0.77	0.47	0.58	488
accuracy			0.84	1983
macro avg	0.81	0.71	0.74	1983
weighted avg	0.83	0.84	0.82	1983

Analiza wyników dla danych zestandaryzowanych i znormalizowanych pokazuje, że oba przekształcenia danych miały zauważalny wpływ na skuteczność modelu.

Porównanie wyników dokładności:

- **Dokładność (Accuracy)** dla danych zestandaryzowanych wyniosła 0.86, natomiast dla danych znormalizowanych 0.84, co sugeruje, że standaryzacja przyniosła lepsze efekty dla ogólnej trafności modelu.

Classification Report dla danych zestandaryzowanych:

- **Klasa 0:** Precision wynosi 0.87, recall 0.96, a F1-score 0.91, co wskazuje na wysoką skuteczność modelu w identyfikacji klasy 0. Model dobrze rozpoznaje tę klasę i rzadko klasyfikuje inne próbki jako klasa 0.
- **Klasa 1:** Wyniki dla klasy 1 są niższe – precision osiąga 0.82, recall 0.55, a F1-score 0.66, co oznacza, że model nie radzi sobie równie dobrze z rozpoznaniem tej klasy. Recall jest stosunkowo niski, co sugeruje, że model często przeocza rzeczywiste przypadki klasy 1.

Classification Report dla danych znormalizowanych:

- **Klasa 0:** Wartość precision to 0.85, recall 0.96, a F1-score 0.90. Wyniki są nieco niższe niż dla danych zestandaryzowanych, ale wciąż wskazują na wysoką skuteczność modelu w identyfikacji klasy 0.
- **Klasa 1:** Wyniki dla klasy 1 są słabsze niż w przypadku danych zestandaryzowanych – precision wynosi 0.77, recall 0.47, a F1-score 0.58. Niska wartość recall sugeruje, że model ma trudności z rozpoznawaniem tej klasy, co jest widoczne w jeszcze niższej skuteczności niż na danych zestandaryzowanych.

Standaryzacja i normalizacja nie wpłynęły korzystnie na ogólną dokładność modelu, która okazała się niższa niż dla danych oryginalnych, nawet po optymalizacji. Mimo że standaryzacja poprawiła nieco wyniki dla poszczególnych klas (zwłaszcza klasy 1), ogólna trafność (accuracy) modelu była najlepsza dla danych oryginalnych z optymalizacją, co sugeruje, że przekształcenia te nie były kluczowe dla poprawy efektywności klasyfikacji.

4.4. Maszyna Wektorów Nośnych (SVM)

Uzyskane wyniki dla modelu SVM dla oryginalnych, nieskalowanych danych:

```
Confusion Matrix:
[[1417   78]
 [ 156  332]]

Classification Report:

```

	precision	recall	f1-score	support
0	0.90	0.95	0.92	1495
1	0.81	0.68	0.74	488
accuracy			0.88	1983
macro avg	0.86	0.81	0.83	1983
weighted avg	0.88	0.88	0.88	1983

```
Accuracy: 0.8819969742813918
```

Analiza wyników modelu SVM pokazuje, że osiągnął on solidną skuteczność w klasyfikacji.

Analiza Confusion Matrix:

- **True Negatives (1417):** Model poprawnie przewidział 1417 przypadków, gdzie wynik był poniżej 70%.
- **False Positives (78):** W 78 przypadkach model przewidział wynik powyżej 70%, choć rzeczywisty wynik był poniżej tego progu.
- **False Negatives (156):** Model błędnie zaklasyfikował 156 przypadków, gdzie wynik był powyżej 70%, jako wynik poniżej 70%.
- **True Positives (332):** Model poprawnie przewidział 332 przypadków, w których wynik był powyżej 70%.

Raport klasyfikacji:

- Klasa 0 (wynik poniżej 70%):
 - **Precyzja:** 0.90 — Oznacza to, że 90% przypadków, w których model przewidywał wynik poniżej 70%, było poprawnych.
 - **Recall:** 0.95 — Model poprawnie zidentyfikował 95% rzeczywistych przypadków z wynikiem poniżej 70%.
 - **F1-score:** 0.92 — Wysoki F1-score wskazuje na dobrą równowagę między precyzją a recall dla tej klasy.
- Klasa 1 (wynik powyżej 70%):
 - **Precyzja:** 0.81 — 81% przewidywań wyniku powyżej 70% było poprawnych.
 - **Recall:** 0.68 — Model poprawnie zidentyfikował 68% rzeczywistych przypadków powyżej 70%.
 - **F1-score:** 0.74 — Wynik F1-score dla tej klasy jest niższy niż dla klasy 0 co sugeruje, że model ma trudności z dokładnym rozpoznaniem tej klasy w porównaniu do klasy 0.

Dokładność (Accuracy): 0.88 — Model poprawnie klasyfikuje 88% wszystkich przypadków. Jest to dobry wynik, choć widać, że model lepiej radzi sobie z klasyfikacją wyników poniżej 70% niż powyżej, co może wskazywać na pewną nierównowagę w rozpoznawaniu obu klas.

Wyniki SVM z zastosowaną optymalizacją:

```
Confusion Matrix (optimized):
[[1453  42]
 [ 78 410]]

Classification Report (optimized):
              precision    recall  f1-score   support

     0       0.95       0.97       0.96       1495
     1       0.91       0.84       0.87       488

 accuracy          0.94          1983
 macro avg         0.93          1983
weighted avg         0.94          1983

Accuracy (optimized): 0.94
```

Na podstawie wyników po optymalizacji dla modelu SVM możemy zauważyć znaczną poprawę w klasyfikacji w porównaniu do wyników przed optymalizacją.

Analiza Confusion Matrix po optymalizacji:

- **True Negatives:** Wzrost z 1417 do 1453 — model poprawnie klasyfikuje 36 przypadków więcej jako wyniki poniżej 70%.
- **False Positives:** Spadek z 78 do 42 — o 36 przypadków mniej, w których model błędnie przewidział wynik powyżej 70% dla rzeczywistego wyniku poniżej tego progu.
- **False Negatives:** Spadek z 156 do 78 — model o połowę zmniejszył liczbę przypadków, w których wynik powyżej 70% został błędnie zaklasyfikowany jako poniżej 70%.
- **True Positives:** Wzrost z 332 do 410 — model poprawnie klasyfikuje 78 dodatkowych przypadków z wynikiem powyżej 70%.

Porównanie raportu klasyfikacji:

- **Klasa 0 (wynik poniżej 70%):**
 - **F1-score:** Wzrost z 0.92 do 0.96 — optymalizacja wyraźnie poprawiła zrównoważenie precyzji i czułości dla tej klasy.
 - **Precyzja:** Wzrost z 0.90 do 0.95 — teraz 95% przewidywań wyników poniżej 70% jest poprawnych.
 - **Recall:** Wzrost z 0.95 do 0.97 — model jeszcze lepiej wykrywa wyniki poniżej 70%.

- **Klasa 1 (wynik powyżej 70%):**

- **F1-score:** Wzrost z 0.74 do 0.87 — model znacząco poprawił swoją skuteczność w rozpoznawaniu wyników powyżej 70%.
- **Precyzja:** Wzrost z 0.81 do 0.91 — teraz 91% przewidywań wyników powyżej 70% jest poprawnych.
- **Recall:** Wzrost z 0.68 do 0.84 — model lepiej identyfikuje rzeczywiste przypadki wyników powyżej 70%.

Dokładność (Accuracy): Wzrost z 0.88 do 0.94, co oznacza, że model poprawnie klasyfikuje 94% przypadków po optymalizacji, co jest wyraźną poprawą w stosunku do wyniku przed optymalizacją.

Optymalizacja modelu SVM przyniosła znaczną poprawę w klasyfikacji, szczególnie dla klasy wyników powyżej 70%, gdzie wzrosły wszystkie miary: precyzja, recall i F1-score. Zmniejszenie liczby błędnych klasyfikacji dla obu klas, a także wzrost ogólnej dokładności, wskazuje na lepsze dopasowanie modelu po optymalizacji i zwiększoną skuteczność w odwzorowywaniu rzeczywistego podziału na klasy.

Wyniki SVM dla danych zestandaryzowanych i znormalizowanych:

Accuracy on Standardized Data: 0.93				
Accuracy on Normalized Data: 0.93				
Classification Report (Standardized):				
	precision	recall	f1-score	support
0	0.94	0.97	0.95	1495
1	0.91	0.80	0.85	488
accuracy			0.93	1983
macro avg	0.92	0.88	0.90	1983
weighted avg	0.93	0.93	0.93	1983
Classification Report (Normalized):				
	precision	recall	f1-score	support
0	0.93	0.98	0.95	1495
1	0.91	0.78	0.84	488
accuracy			0.93	1983
macro avg	0.92	0.88	0.90	1983
weighted avg	0.93	0.93	0.93	1983

Analiza wyników dla danych zestandaryzowanych i znormalizowanych pokazuje, że oba przekształcenia miały podobny wpływ na skuteczność modelu.

Porównanie wyników dokładności:

- Dokładność (Accuracy) dla danych zestandaryzowanych i znormalizowanych wyniosła 0.93, co wskazuje, że oba podejścia nie wpłynęły znacząco na poprawę ogólnej trafności modelu, pozostawiając ją na takim samym poziomie.

Classification Report dla danych zestandaryzowanych:

- **Wynik poniżej 70% (Klasa 0):** Precision wynosi 0.94, recall 0.97, a F1-score 0.95, co sugeruje wysoką skuteczność modelu w identyfikacji tej klasy. Model dobrze rozpoznaje próbki klasy 0 i rzadko przypisuje inne próbki do tej klasy.
- **Wynik powyżej 70% (Klasa 1):** Precision wynosi 0.91, recall 0.80, a F1-score 0.85, co oznacza, że model radzi sobie dobrze z klasyfikacją tej klasy, choć recall wskazuje, że część rzeczywistych przypadków klasy 1 jest błędnie klasyfikowana.

Classification Report dla danych znormalizowanych:


- **Wynik poniżej 70% (Klasa 0):** Precision wynosi 0.93, recall 0.98, a F1-score 0.95. Wyniki są podobne do zestandaryzowanych danych, choć model jeszcze lepiej wyłapuje klasę 0 (wyższy recall).
- **Wynik powyżej 70% (Klasa 1):** Precision wynosi 0.91, recall 0.78, a F1-score 0.84, co jest zbliżone do wyników dla danych zestandaryzowanych, choć recall jest nieco niższy.

Standaryzacja i normalizacja danych dały porównywalne rezultaty, jednak żadna z metod przekształcenia nie poprawiła dokładności modelu powyżej wyników dla danych oryginalnych po optymalizacji. Standaryzacja i normalizacja nie wpłynęły znacząco na ogólną skuteczność klasyfikacji, choć mogły nieznacznie poprawić stabilność predykcji między klasami.

4.5. Wykresy


Wyniki miar klasyfikacji, takich jak accuracy, precision, recall oraz F1-score, zostały zaprezentowane graficznie, aby umożliwić porównanie efektywności różnych modeli - Logistic Regression, KNN oraz SVM. Dla każdej miary przedstawiono oddzielny wykres, które ukazuje jej wartość uzyskaną przez różne modele na różnych danych (oryginalnych, zestandaryzowanych i znormalizowanych).

Accuracy




Najlepsza wartość accuracy - 94% - została osiągnięta dla modelu Logistic Regression dla wszystkich rodzajów danych. Model SVM również osiągnął wysoki wynik 93% dla danych zestandaryzowanych i znormalizowanych. Spośród tych trzech modeli najgorsze wyniki osiągnął model KNN dla danych znormalizowanych - 84%.

Precision




Podobnie jak w przypadku Accuracy, najlepiej wypadł model Logistic Regression z uzyskaną wartością precision 94% dla wszystkich rodzajów danych. Ponownie model SVM miał różnicę 1% dla danych zestandaryzowanych i znormalizowanych. Najgorsze wyniki Precision uzyskał model KNN dla danych znormalizowanych - 83%.

Recall



Największy odsetek prawdziwych przypadków pozytywnych zidentyfikowanych przez model uzyskał model Logistic Regression - ponownie dla wszystkich danych 94%. Model SVM osiągnął 93% dla danych zestandaryzowanych i znormalizowanych. Najgorszą wartość Recall uzyskał model KNN dla danych znormalizowanych.

F1- score



Najlepszy wynik F1 score uzyskał model Logistic Regression - 94% dla wszystkich danych, następnie model SVM dla danych zestandaryzowanych i znormalizowanych - 93%. Najmniejszą wartość F1 uzyskał model KNN dla danych znormalizowanych.

Podsumowując w przypadku modelu Regresji Logistycznej standaryzacja i normalizacja danych nie wpłynęła w ogóle na wyniki miar klasyfikacji - wszystkie pozostały na tym samym poziomie 94%. Dla modelu KNN standaryzacja i normalizacja danych wpłynęła negatywnie - model dla tych danych osiągnął do 5% gorsze wyniki. Model SVM osiągnął wszystkie miary klasyfikacji dla danych oryginalnych na poziomie 88%, natomiast dla danych zestandaryzowanych i znormalizowanych wszystkie miary były na poziomie 93%, zatem standaryzacja i normalizacja danych wpłynęła pozytywnie na wyniki predykowania modelu.

4. PODSUMOWANIE

Najlepiej działający model: Regresja logistyczna

Spośród analizowanych modeli najwyższą stabilność oraz skuteczność wykazał model regresji logistycznej, który osiągnął stałe wskaźniki klasyfikacyjne na poziomie 94% dla Accuracy, Precision, Recall oraz F1-score, niezależnie od przekształceń danych. Model ten nie tylko wykazał największą stabilność wyników, ale również bardzo dobrze rozpoznawał oba typy klas, co oznacza wysoką równowagę między precyzją a skutecznością rozpoznawania zarówno uczniów osiągających wynik powyżej 70%, jak i tych poniżej tego progu. Przeprowadzone optymalizacje w modelu regresji logistycznej nie poprawiły skuteczności modelu. Transformacje danych, takie jak standaryzacja i normalizacja, również nie wpłynęły na poprawę wyników, co dodatkowo potwierdza wysoką efektywność tego modelu dla analizowanego zbioru danych.

Najgorzej działający model: K-Nearest Neighbors (KNN)

Model KNN osiągnął najniższą skuteczność spośród badanych metod, zwłaszcza na danych znormalizowanych, gdzie wskaźniki klasyfikacji, takie jak Accuracy, spadły do poziomu 84%. KNN wykazywał wyraźną trudność w rozróżnianiu klas, co było widoczne w stosunkowo niskiej wartości F1-score dla klasy powyżej 70%. Choć zastosowanie optymalizacji przy użyciu GridSearchCV poprawiło wyniki modelu, szczególnie dla klasy 1, to jednak pozostał on znacznie mniej skuteczny w porównaniu do innych modeli, szczególnie w przewidywaniu poprawnych wyników dla uczniów osiągających lepsze wyniki na egzaminie. W przypadku KNN szczególnie niekorzystnie wpłynęły przekształcenia danych – model najlepiej radził sobie na danych oryginalnych, a każda transformacja obniżała jego wyniki, co może wskazywać, że dla tego modelu istotne są cechy danych w ich pierwotnej formie.

Maszyna wektorów nośnych (SVM)

Model SVM zyskał na jakości klasyfikacji po zastosowaniu standaryzacji i normalizacji danych – wskaźniki takie jak Accuracy, Precision, Recall i F1-score wzrosły z poziomu 88% na danych oryginalnych do 93% na danych przekształconych. Optymalizacja parametrów miała również istotny wpływ na poprawę wyników, szczególnie w zakresie precyzji i czułości dla klasy 1 (czyli uczniów z wynikami powyżej 70%). Zastosowanie odpowiedniego jądra oraz dostrojenie parametru regularyzacji C sprawiło, że model ten zyskał stabilność i znacznie zmniejszył liczbę błędnych klasyfikacji w obu klasach.

Czynniki wpływające na jakość predykcji

1. **Optymalizacja parametrów:** Największe znaczenie miała optymalizacja parametrów w modelach SVM oraz KNN, które znacznie zyskały na dokładności po zastosowaniu odpowiednich hiperparametrów. W przypadku regresji logistycznej i liniowej optymalizacja miała mniejsze znaczenie, sugerując, że te modele w swojej podstawowej wersji dobrze odwzorowywały zależności w danych.
2. **Przekształcenia danych:** Standaryzacja i normalizacja miały największy wpływ na model SVM, dla którego wszystkie miary klasyfikacji wzrosły na danych przekształconych. Dla KNN transformacje danych przyniosły odwrotny efekt,

obniżając wskaźniki klasyfikacyjne, co może wynikać z faktu, że model ten jest szczególnie wrażliwy na zmiany skali i struktury danych.

3. **Zróżnicowanie modeli względem klas:** Każdy z modeli miał inne podejście do rozpoznawania klas. Regresja logistyczna dobrze radziła sobie z oboma typami klas, natomiast modele KNN i SVM wykazywały trudność w skutecznym rozpoznawaniu klasy powyżej 70%, zwłaszcza bez optymalizacji.

Regresja logistyczna okazała się najbardziej efektywnym modelem w przewidywaniu wyników egzaminów powyżej 70%, wykazując wysoką skuteczność i stabilność na różnych wersjach danych. SVM, mimo niższej skuteczności na danych oryginalnych, po standaryzacji i normalizacji osiągnął zbliżone wyniki do regresji logistycznej. Model KNN, szczególnie na danych znormalizowanych, wykazał najniższą skuteczność. Transformacje danych oraz optymalizacja parametrów okazały się kluczowe dla poprawy skuteczności modeli, co podkreśla istotność wyboru odpowiednich technik przetwarzania danych oraz dostrajania hiperparametrów.

5. BIBLIOGRAFIA

- Materiały z ćwiczeń laboratoryjnych.
- Dokumentacja bibliotek Python: pandas, matplotlib, numpy, scikit-learn, seaborn, Statsmodels.